
Deep Learning Hybrid Techniques for Brain Tumor Detection and Segmentation in Medical Images

by Mustafa Güler, Khushboo Munir Fabrizio, Frezza, Ersin Namlı

Khoa Kỹ thuật, Đại học Istanbul University-Cerrahpaşa, Istanbul, Thổ Nhĩ Kỳ.

Khoa Kỹ thuật Thông tin, Điện tử và Viễn thông, Đại học Sapienza University of Rome, Rome,

Ý. *Tác giả liên hệ: iauthor@gmail.com † Các tác giả đóng góp đồng đẳng.

1 Introduction

Sự phát triển của học sâu (Deep Learning - DL) đã mở ra một kỷ nguyên mới trong khoa học dữ liệu, đặc biệt là trong lĩnh vực xử lý hình ảnh y tế. Việc giải thích các hình ảnh chụp cộng hưởng từ (MRI) đòi hỏi độ chính xác và sự tỉ mỉ cực cao, bởi các khối u não có vị trí nhạy cảm và hình thái phức tạp. Các chuyên gia y tế thường phải đối mặt với thách thức lớn khi phân biệt giữa các mô lành tính và ác tính qua hàng nghìn lát cắt MRI mỗi ngày. Do đó, nhu cầu về các hệ thống chẩn đoán hỗ trợ máy tính (CAD) tự động là rất cấp thiết nhằm giảm thiểu sai sót do con người và đẩy nhanh quá trình đưa ra phác đồ điều trị.

Hầu hết các nghiên cứu hiện nay tập trung vào hai mục tiêu cốt lõi: phân loại để xác định loại khối u và phân đoạn để khoanh vùng chính xác ranh giới của khối u đó. Nghiên cứu này đề xuất một phương pháp tiếp cận lai (hybrid) tiên tiến, kết hợp sức mạnh trích xuất đặc trưng của các mạng nơ-ron tích chập (CNN) như VGG, ResNet, DenseNet với các bộ phân loại học máy truyền thống và cấu trúc U-Net cải tiến tích hợp khối Inception để tối ưu hóa hiệu suất chẩn đoán trên các bộ dữ liệu MRI thực tế.

2 Related Work

Trong những năm gần đây, nhiều kỹ thuật xử lý hình ảnh đã được phát triển để hỗ trợ chẩn đoán khối u não. Các kiến trúc CNN như GoogleNet, VGG và ResNet đã chứng minh hiệu quả vượt trội trong việc phân loại các loại u như u tuyến yên, u glioma và u màng não. Một số nghiên cứu sử dụng VGG16 đã đạt được độ chính xác 98% trên các bộ dữ liệu nhỏ, trong khi các mô hình như ResNet50 hay DenseNet121 khi kết hợp với kỹ thuật tăng cường dữ liệu và tối ưu hóa tham số có thể đẩy độ chính xác lên tới mức tuyệt đối.

Về bài toán phân đoạn, kiến trúc U-Net đã trở thành một tiêu chuẩn nhờ cấu trúc mã hóa-giải mã (encoder-decoder) mạnh mẽ. Các nghiên cứu hiện đại đã cải tiến mô hình này bằng cách tích hợp các khối Inception, cho phép mạng học các đặc trưng ở nhiều quy mô khác nhau (đa quy mô) đồng thời. Việc áp dụng tích chập tách biệt theo chiều sâu (depth-wise separable convolution) cũng đang trở thành một xu hướng quan trọng, giúp giảm đáng kể chi phí tính toán và số lượng tham số mà vẫn duy trì hoặc thậm chí cải thiện được chỉ số tương đồng Dice và độ nhạy trong việc khoanh vùng khối u.

3 Method

3.1 Datasets

Nghiên cứu sử dụng sự kết hợp của các bộ dữ liệu MRI lớn và uy tín:

- **Bộ dữ liệu MRI khối u não (Kaggle):** Tổng cộng 7022 hình ảnh được chia thành 4 lớp: u glioma, u ác tính, u tuyến yên và không có khối u. Dữ liệu được phân chia theo tỷ lệ 60% để huấn luyện và 40% để kiểm tra.
- **Bộ dữ liệu BraTS 2019:** Gồm hình ảnh của 335 bệnh nhân với đầy đủ 4 loại xung MRI (T1, T2, T1c, FLAIR), được dán nhãn thủ công bởi các chuyên gia nơ-ron học.

3.2 Hybrid Classification Architecture

Hệ thống phân loại sử dụng bốn kiến trúc CNN (VGG, ResNet, DenseNet, SqueezeNet) làm bộ trích xuất đặc trưng. Các đặc trưng thu được sẽ được đưa vào các thuật toán học máy truyền thống như SVM, k-NN và Cây quyết định. Để đạt hiệu suất tối ưu, quy trình Grid Search được thực hiện để tinh chỉnh các siêu tham số như tốc độ học (learning rate), số vòng lặp (epochs) và kích thước lô (batch size), kết hợp với các hàm tối ưu hóa như Adam và SGD.

3.3 Segmentation Architecture with Inception Blocks

Đối với bài toán phân đoạn, chúng tôi đề xuất cấu trúc **DS-Hybrid U-Net**. Mô hình này tích hợp các khối Inception vào từng tầng của quá trình mã hóa và giải mã để thu thập ngữ cảnh tốt hơn ở các kích thước bộ lọc khác nhau (3x3, 5x5, 7x7). Việc sử dụng tích chập tách biệt theo chiều sâu giúp mô hình nhẹ hơn và xử lý nhanh hơn. Ngoài ra, một hàm mất mát mới dựa trên hệ số tương đồng Dice (DSC) đã được phát triển để giải quyết tình trạng mất cân bằng dữ liệu giữa các vùng khối u nhỏ và vùng mô khỏe mạnh chiếm đa số trong ảnh.

4 References

1. LeCun, Y., Bengio, Y., Hinton, G.: Deep learning. *Nature* 521, 436–444 (2015)
2. Güler, M., Namlı, E.: Brain Tumor Detection with Deep Learning Methods' Classifier Optimization Using Medical Images. *Appl. Sci.* 14(2), 642 (2024)
3. Munir, K., Frezza, F., Rizzi, A.: Deep Learning Hybrid Techniques for Brain Tumor Segmentation. *Sensors* 22(21), 8201 (2022)
4. Ronneberger, O., Fischer, P., Brox, T.: U-net: Convolutional networks for biomedical image segmentation. In: *MICCAI*, pp. 234–241 (2015)
5. Szegedy, C., et al.: Going deeper with convolutions. In: *Proc. IEEE CVPR*, pp. 1–9 (2015)
6. Bakas, S., et al.: Identifying the best machine learning algorithms for brain tumor segmentation in the BRATS challenge. *arXiv:1811.02629* (2018)
7. Howard, A.G., et al.: MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. *arXiv:1704.04861* (2017)
8. Mathew, A., Amudha, P., Sivakumari, S.: Deep Learning Techniques: An Overview. In: *AMLTA*, pp. 599–608. Springer (2020)
9. Myronenko, A.: 3D MRI brain tumor segmentation using autoencoder regularization. In: *International MICCAI Brainlesion Workshop*, pp. 311–320 (2018)