

Swin-Unet: Unet-like Pure Transformer for Medical Image Segmentation

Tác giả: Cao, H., et al. – Springer ECCV (2022)

1. Introduction

Bối cảnh và Tầm quan trọng: Phát hiện sớm khối u não là một trong những thách thức quan trọng nhất trong chẩn đoán hình ảnh y tế. Việc xác định chính xác vị trí, kích thước và loại khối u ngay từ giai đoạn đầu có tác động trực tiếp đến hiệu quả điều trị và tỷ lệ sống sót của bệnh nhân. Tuy nhiên, các phương pháp tiếp cận tập trung truyền thống đang đối mặt với những rào cản lớn về quyền riêng tư dữ liệu (tuân thủ HIPAA, GDPR) và sự thiếu hụt dữ liệu đa dạng từ các tổ chức y tế khác nhau.

Sự dịch chuyển từ CNN sang Capsule Networks: Thay vì sử dụng các mạng nơ-ron tích chập (CNN) truyền thống—vốn bị hạn chế bởi việc mất thông tin không gian do các lớp pooling và khó nắm bắt các mối quan hệ phân cấp—nghiên cứu này giới thiệu kiến trúc

Aniso-ResCapHGBO-Net. Trọng tâm của kiến trúc này là mạng **Capsule (CapsNets)**. Khác với CNN, CapsNets sử dụng các vector để mã hóa định hướng và mối quan hệ "bộ phận-thể thống nhất" (part-whole relationships). Điều này giúp mô hình đạt được khả năng bất biến với các phép xoay và giữ nguyên cấu trúc không gian của ảnh MRI/CT, từ đó giảm tỷ lệ dương tính giả mà các mạng CNN thông thường thường gặp phải.

Thách thức và Giải pháp Phi tập trung: Để giải quyết bài toán bảo mật, khung làm việc đề xuất sử dụng **Học liên hợp (Federated Learning - FL)**. Phương pháp này cho phép 5 client (mô phỏng các bệnh viện) cùng huấn luyện một mô hình chung mà không cần chia sẻ dữ liệu thô. Sự kết hợp giữa FL, mạng Capsule và cơ chế bảo mật **Blockchain** tạo ra một hệ thống chẩn đoán mạnh mẽ, có khả năng học từ dữ liệu không đồng nhất (Non-IID) đồng thời bảo vệ tuyệt đối thông tin bệnh nhân.

Mục tiêu báo cáo Báo cáo này trình bày chi tiết về khung làm việc phi tập trung, sử dụng thuật toán tối ưu hóa lai **HGBOA** để chọn lọc đặc trưng và mạng **Ethereum** riêng tư để đảm bảo tính minh bạch trong quá trình cập nhật mô hình.

2. Related Work

Hạn chế của các phương pháp truyền thống: Các kỹ thuật kinh điển như SVM, KNN và ngay

cả CNN truyền thống đã bộc lộ những điểm yếu trong phân tích hình ảnh y tế quy mô lớn:

- **CNN:** Gặp khó khăn trong việc xử lý các khối u có hình dạng bất thường và vị trí thay đổi do thiếu khả năng nhạy bén không gian (spatial sensitivity).
- **SVM và KNN:** Dễ bị quá tải khi đối mặt với dữ liệu hình ảnh có số chiều cao và thường yêu cầu các đặc trưng thủ công (handcrafted features) vốn không thể bao quát hết thông tin ngữ cảnh sâu.
- **Hệ thống tập trung:** Dễ dẫn đến rủi ro rò rỉ dữ liệu và vi phạm các quy định bảo mật y tế nghiêm ngặt.
-

Các kiến trúc tiền đề: Nghiên cứu kế thừa và cải tiến từ các công trình tiêu biểu như mạng **dResU-Net** của Raza et al. (phân đoạn đa biến 3D) và **Mask R-CNN** của Padma et al. Tuy nhiên, các kiến trúc này thường đòi hỏi tài nguyên tính toán cực lớn và dễ bị quá khớp (overfitting) khi tập dữ liệu gán nhãn bị hạn chế. Sự ra đời của FL và kiến trúc lai ResNet-Capsule được xem là lời giải cho sự cân bằng giữa độ chính xác và tính bảo mật.

3. Method

3.1. Quy trình Tiền xử lý và Dịch thuật Hình ảnh

Quy trình tiền xử lý được thiết kế để chuẩn hóa dữ liệu từ nhiều nguồn khác nhau:

- **Dịch thuật ảnh bằng CycleGAN:** Để giải quyết sự khan hiếm dữ liệu MRI, mô hình CycleGAN được huấn luyện để chuyển đổi ảnh CT sang ảnh MRI tổng hợp. Việc bổ sung dữ liệu này giúp tăng độ chính xác thêm 0,2–0,3% và giảm thiểu sai lệch tên miền (MMD đạt 0,042).
- **Đăng ký ảnh dựa trên Thông tin tương hỗ (Mutual Information - MI):** Kỹ thuật này giúp căn chỉnh các lát cắt hình ảnh từ các thiết bị CT/MRI khác nhau bằng cách tối đa hóa sự phụ thuộc thông tin giữa chúng, đảm bảo tính nhất quán cho các client trong mạng liên hợp.
- **Lọc khuếch tán dị hướng (Anisotropic Diffusion Filtering):** Giảm nhiễu tối đa trong khi vẫn bảo toàn được các biên cạnh quan trọng của khối u.
- **Phép toán hình thái học (Morphological Operations):** Sử dụng các phần tử cấu trúc dạng đĩa để loại bỏ mô không phải não thông qua các phép toán xói mòn ($A \ominus B$) và giãn nở ($A \oplus B$).
- **Chuẩn hóa Min-max:** Đưa giá trị pixel về dải $[0, 1]$ để đảm bảo tính ổn định khi hội tụ.

3.2. Kiến trúc Phân đoạn và Phân loại

Mô hình **Aniso-ResCapHGBO-Net** tích hợp các thành phần tối tân:

Mạng Capsule (ResCapFed-Net): Sử dụng cơ chế định tuyến động (dynamic routing)

và hàm kích hoạt **Squashing** để chuẩn hóa xác suất hiện diện của khối u. Cách tiếp cận này giúp mô hình nhận diện chính xác các "part-whole relationships", vượt trội hơn hẳn CNN trong việc xác định các khối u có biên giới mờ hoặc hình dạng phức tạp.

3.3. Trích xuất và Chọn lọc Đặc trưng bằng HGBOA

Hệ thống kết hợp ba loại đặc trưng: kết cấu (GLCM), thống kê (Mean, SD, Skewness, Kurtosis) và đặc trưng sâu từ **ResNet-50**.

- **Thuật toán lai Gorilla Badger (HGBOA):** Đây là sự kết hợp giữa **GTO** (Gorilla Troops Optimization) và **HBA** (Honey Badger Algorithm).
 - **GTO:** Đóng vai trò thăm dò toàn cục (exploration) dựa trên cấu trúc phân cấp lãnh đạo của đàn gorilla.
 - **HBA:** Đóng vai trò khai thác cục bộ (exploitation) thông qua bộ nhớ thích nghi và hành vi tìm kiếm theo cường độ của lợn mật.
- **Hiệu quả:** HGBOA đạt tỷ lệ giảm đặc trưng (**FRR**) ấn tượng là **28,6%**, thấp hơn nhiều so với các thuật toán đơn lẻ, giúp mô hình gọn nhẹ và hội tụ nhanh hơn (chỉ sau 51 vòng lặp).

3.4. Học liên hợp và Bảo mật Blockchain

Hệ thống triển khai cơ chế phi tập trung nghiêm ngặt:

- **Blockchain riêng tư (Ethereum):** Sử dụng cơ chế đồng thuận **Proof of Authority (PoA)** để tối ưu tốc độ. Thay vì lưu dữ liệu thô, Blockchain chỉ lưu trữ mã băm (**SHA-256**) của các trọng số mô hình.
 - Thời gian tạo khối: **3,1 giây**.
 - Độ trễ cập nhật: **5,4 giây**.
 - Chi phí lưu trữ: Chỉ khoảng **3,8 KB/node** mỗi vòng.
- **An toàn dữ liệu:** Sự kết hợp giữa mã hóa và nhiễu vi phân (Differential Privacy) giúp giảm rủi ro rò rỉ dữ liệu xuống còn **2,1%**, trong khi độ chính xác vẫn duy trì ở mức **99,07%**.

4. References

- Al-Saleh, A., Tejani, G. G., Mishra, S., Sharma, S. K., & Mousavirad, S. J. (2025). A federated learning-based privacy-preserving image processing framework for brain tumor detection from CT scans. *Scientific Reports*.
- Raza, R. et al. (2022). dResU-Net: 3D deep residual U-Net for multimodal MRI segmentation.
- Ranjbarzadeh, R. et al. (2023). Optimized CNN using improved chimp optimization algorithm for brain tumor detection.

- Padma, A. et al. (2021). Mask R-CNN for image segmentation in tumor detection.
- Bhagat, S., & Kaur, P. (2023). SVM for MRI image classification in brain tumor diagnosis.
- Kascenas, A. et al. (2023). Unsupervised anomaly detection using denoising autoencoders in brain MRI.
- Srinivas, M. et al. (2023). Deep transfer learning approaches for MRI classification.
- Aggarwal, A. (2023). Random forest classifier with GLCM features for MRI analysis.